

Documentación de Arquitectura: Implementación de Data Lakehouse

1. Resumen Ejecutivo

Este documento describe la arquitectura técnica del sistema de datos implementado para el proyecto Steam Hidden Gem Score, desarrollado por el Equipo 3 como parte del curso de Ingeniería de Datos en la Facultad de Ingeniería de la UNAM. El objetivo del proyecto es identificar videojuegos subvalorados en la plataforma Steam mediante un índice ponderado (Hidden Gem Score, HGS) que combina calidad percibida, obscuridad y precio accesible.

El sistema extrae datos de las APIs públicas de SteamSpy y Steam Store, los almacena y procesa a través de una arquitectura Medallion sobre AWS (Bronze, Silver, Gold), y expone los resultados mediante un dashboard de Streamlit orientado al equipo de marketing de Steam.

2. Diagrama de Arquitectura (Conceptual)

La solución se basa en una arquitectura Medallion (Bronze, Silver, Gold) utilizando servicios gestionados de AWS para garantizar escalabilidad, trazabilidad y calidad de datos en cada etapa del pipeline.

El flujo general sigue la siguiente secuencia:

- Steam API pública → Extracción con Python script programado mediante CRON y orquestado por EventBridge Scheduler
- Bronze Layer → almacenamiento de datos crudos en formato JSONL en Amazon S3
- AWS Glue (ETL + Data Quality) → limpieza, validación con 12 reglas EvaluateDataQuality, y escritura en Parquet
- Silver Layer → datos validados en S3, listos para cálculo del score
- HGS Calc → aplicación de la fórmula del Hidden Gem Score
- Gold Layer → carga en Amazon RDS PostgreSQL para consumo final

3. Stack Tecnológico

Componente	Servicio AWS	Rol en el Pipeline
Almacenamiento (Data Lake)	Amazon S3	Capas Bronze, Silver y Gold en buckets particionados por fecha
Ingesta y orquestación	Python + EventBridge	Script de extracción con CRON; EventBridge como scheduler automático

ETL y calidad de datos	AWS Glue	Job ETL con EvaluateDataQuality (12 reglas); salida en Parquet/Snappy
Catálogo de metadatos	AWS Glue Data Catalog	Registro de esquemas de tablas para Bronze y Silver
Capa de consumo (Gold)	Amazon RDS PostgreSQL	Base de datos relacional para consultas analíticas y dashboard
Monitoreo	Amazon CloudWatch	Logs de ejecución del Glue Job y alertas de fallos
Seguridad	AWS IAM	Roles con menor privilegio (TEST-GLUE-ROLE y derivados)

4. Descripción de Capas (Medallion Architecture)

Capa	Descripción del Proceso	Formato	Tecnología
Bronze (Raw)	Datos en formato original tal como se obtienen de las APIs de SteamSpy y Steam Store. Sin transformaciones, preservando la trazabilidad completa.	JSONL	S3, Python script
Silver (Trusted)	Datos validados con 12 reglas de calidad (completitud, rangos, consistencia lógica). Tipos corregidos, registros nulos en columnas clave eliminados. Juegos free-to-play (precio = 0) soportados explícitamente.	Parquet / Snappy	AWS Glue ETL + EvaluateDataQuality
Gold (Refined)	Aplicación de la fórmula HGS ponderada: 50% calidad percibida, 30% obscuridad, 20% precio. Datos listos para consulta analítica y dashboard.	Tablas relacionales	RDS PostgreSQL, HGS Calc

5. Flujo de Datos (Pipeline)

El pipeline sigue las siguientes etapas en orden:

- El script de Python consulta las APIs de SteamSpy y Steam Store; EventBridge Scheduler lanza la extracción de forma periódica.
- Los datos crudos se depositan en S3 Bronze en formato JSONL, particionados por fecha de extracción.

- El job de AWS Glue (TEST-GLUE-JOB-DATA-QUALITY) se activa, aplica las 12 reglas de EvaluateDataQuality y escribe el resultado validado en S3 Silver en formato Parquet comprimido con Snappy.
- El módulo HGS Calc aplica la fórmula ponderada sobre los datos Silver para calcular el score de cada juego.
- Los resultados se cargan en RDS PostgreSQL (Gold) mediante conexión JDBC, quedando disponibles para el dashboard de Streamlit y para consultas analíticas del equipo de negocio.
- CloudWatch registra logs de cada ejecución del Glue Job y lanza alarmas en caso de fallo.

6. Preguntas de Negocio Respondidas

La arquitectura está diseñada para responder tres preguntas de negocio clave, alineadas con el caso de uso de un equipo de marketing interno de Steam:

#	Pregunta de Negocio	Capa que la resuelve
1	¿Qué juegos tienen alta calidad percibida pero baja visibilidad? (candidatos para promover)	Gold — HGS Score ranking
2	¿Qué géneros concentran más joyas ocultas?	Gold — agregación por género
3	¿Qué juegos están subiendo en score entre extracciones?	Gold — comparación histórica entre runs

7. Consideraciones de Seguridad

Se utilizaron roles de IAM con el principio de menor privilegio para limitar el acceso de cada servicio exclusivamente a los recursos que requiere. El rol TEST-GLUE-ROLE otorga permisos de lectura/escritura únicamente sobre los buckets S3 del proyecto y permisos de conexión a RDS. Las credenciales no se almacenan en el código fuente; se resuelven vía variables de entorno y la capa de gestión de secretos de AWS.