

Statement of Work (SOW) - Proyecto de Implementación de Data Lake

Proyecto: Steam Data — Hidden Gem Score (HGS)

Equipo: Equipo 3 — Curso Ingeniería de Datos — Facultad de Ingeniería, UNAM

Statement of Work versión 1.0 — Mayo 2026

2. Resumen del Proyecto

El objetivo del proyecto es diseñar y construir una arquitectura de Data Lake basada en Amazon S3 que permita el almacenamiento escalable y el procesamiento analítico de grandes volúmenes de datos, facilitando la toma de decisiones basada en información precisa y oportuna.

La solución implementará:

- Ingesta automatizada de datos desde las APIs públicas de SteamSpy y Steam Store mediante Python y EventBridge Scheduler.
- Arquitectura Medallion con capas Bronze, Silver y Gold.
- Procesamiento ETL/ELT utilizando AWS Glue con validaciones de calidad EvaluateDataQuality y transformación a formato Parquet.
- Catálogo de metadatos mediante AWS Glue Data Catalog.
- Almacenamiento de resultados refinados y cálculo del Hidden Gem Score en Amazon RDS PostgreSQL.
- Monitoreo y alertamiento mediante Amazon CloudWatch.
- Controles de seguridad bajo el principio de menor privilegio utilizando IAM.

3. Alcance del Trabajo (Scope of Work)

El equipo consultor será responsable de las siguientes actividades:

3.1 Ingesta de Datos

- Desarrollo de scripts Python para extracción de datos desde SteamSpy y Steam Store.
- Configuración de ejecuciones automáticas mediante Amazon EventBridge Scheduler.
- Registro de eventos y monitoreo de cargas en CloudWatch.
- Almacenamiento de datos crudos en formato JSONL en la capa Bronze de Amazon S3.

3.2 Almacenamiento y Organización

- Implementación de una arquitectura de tres capas (Bronze, Silver y Gold).
- Configuración de buckets Amazon S3 particionados por fecha.
- Organización de datos siguiendo mejores prácticas de gobierno y trazabilidad.

3.3 Procesamiento ETL/ELT

- Desarrollo de procesos ETL en AWS Glue.
- Conversión de datos de JSONL a Parquet comprimido con Snappy.
- Validación mediante 12 reglas EvaluateDataQuality.
- Eliminación de registros inválidos y normalización de tipos de datos.
- Cálculo del Hidden Gem Score mediante fórmula ponderada.
- Escritura de datos refinados en la capa Gold y carga a PostgreSQL.

3.4 Capa Analítica

- Configuración de Amazon RDS PostgreSQL como capa Gold para consumo analítico.
- Exposición de resultados mediante dashboard Stream.
- Disponibilidad de rankings históricos y análisis comparativos entre ejecuciones.
- Generación de métricas por género, score y tendencias de videojuegos.

3.5 Seguridad y Monitoreo

- Configuración de roles IAM bajo el principio de menor privilegio.
- Configuración de monitoreo mediante CloudWatch.
- Definición de alarmas para fallos de ejecución y errores de procesamiento.

4. Entregables

Se espera la entrega de los siguientes elementos para la validación

Entregable	Descripción
Documento de Arquitectura	Diagrama detallado de los servicios de AWS y flujo de datos.
Scripts de Infraestructura	Código (Terraform/CloudFormation) para el despliegue de S3 y roles IAM.
Código de transformación	Scripts de Python/PySpark utilizados para los procesos de limpieza.
Manual de operación	Guía técnica para el mantenimiento de los pipelines.

5. Cronograma Estimado

1. **Semana 1:** Levantamiento de requerimientos y diseño de arquitectura.
2. **Semana 2-12:** Desarrollo de ingesta y capas de almacenamiento.
3. **Semana 13-15:** Pruebas de calidad de datos (QA).
4. **Semana 16:** Entrega final.

6. Criterios de Aceptación

El proyecto se considerará finalizado cuando los datos en la capa final coincidan con las reglas de negocio establecidas y la latencia de procesamiento esté dentro de los rangos acordados.

Aceptado